Université du Québec à Chicoutimi
Département d'informatique et de mathématique

# SideLine AI

## Système d'Analyse Vidéo Temps Réel pour Matchs de Hockey sur Glaces

Rapport de Projet Final

**8INF883 — Vision Artificielle et Traitement d'Images**

Session : Hiver 2025

Enseignant : **Julien Maitre**

**Équipe**

KRETZ, Victor
MORIN, Alban
TROILLARD, Romain
POURCINE, Mattéo

27 avril 2026

# Résumé

Ce rapport présente *SideLine AI*, un système de vision par ordinateur dédié à l'analyse automatisée de matchs de hockey sur glace. Le système intègre de manière plusieurs briques de traitement d'images : détection et segmentation d'instances par YOLO26, suivi multi-objets par ByteTrack, reconnaissance optique de caractères (OCR) via EasyOCR, et transformation homographique pour la projection des positions sur une représentation 2D normalisée de la patinoire. L'approche repose exclusivement sur des modèles pré-entraînés ou fine-tunés spécifiquement pour ce domaine, ce qui soulève des questions méthodologiques particulières relatives à l'évaluation quantitative en l'absence de *ground truth* annoté. Ce rapport détaille l'ensemble de la chaîne de traitement, les choix architecturaux, et propose une évaluation qualitative accompagnée de perspectives d'amélioration.



**Mots-clés :** vision par ordinateur, détection d'objets, suivi multi-objets, homographie, OCR, YOLO, ByteTrack, analyse sportive, hockey.


Lien vers le projet : `https://github.com/Mino1289/SideLine-AI`

# Table des matières


**1 Objectif de l'Application** **4**
1.1 Définition du Problème . . . . . 4
1.2 Portée Fonctionnelle . . . . . 4

**2 Intention et Motivation** **4**
2.1 Contexte Industriel et Scientifique . . . . . 4
2.2 Contribution Pédagogique . . . . . 5

**3 Données Utilisées** **5**
3.1 Séquence Vidéo Source . . . . . 5
3.2 Absence de Dataset Annoté : Justification . . . . . 5
3.3 Rosters et Métadonnées d'Équipes . . . . . 6

**4 Méthodologie et Pipeline de Traitement** **6**
4.1 Vue d'Ensemble de l'Architecture Système . . . . . 6
4.2 Phase 1 : Initialisation du Système . . . . . 7
4.3 Phase 2 : Détection des Joueurs (Branche Segmentation) . . . . . 7
4.3.1 Expérimentations initiales et sélection du modèle . . . . . 7
4.4 Phase 3 : Classification par K-means (Espace HSV) . . . . . 8
4.5 Phase 4 : Détection des Keypoints et de la Rondelle (Branche Keypoints) 8
4.6 Phase 5 : Calcul de l'Homographie . . . . . 9
4.7 Phase 6 : Identification OCR des Numéros de Maillots . . . . . 9
4.8 Phase 7 : Rendu et Composition Finale . . . . . 9

**5 Architecture des Réseaux de Neurones** **10**
5.1 YOLO26 — Détection et Segmentation . . . . . 10
5.1.1 Justification du Choix . . . . . 10
5.1.2 Deux Modèles, Deux Fonctions . . . . . 10
5.2 ByteTrack — Suivi Multi-Objets . . . . . 10
5.3 EasyOCR — Reconnaissance de Caractères . . . . . 10
5.4 ViTPose — Estimation de Pose (Phase Exploratoire) . . . . . 11
5.5 Optimisation par OpenVINO . . . . . 11

**6 Analyse des Résultats** **11**
6.1 Contexte Évaluatif et Limitations Méthodologiques . . . . . 11
6.2 Évaluation Qualitative par Inspection Visuelle . . . . . 12
6.3 Robustesse aux Conditions Dégradées . . . . . 12
6.4 Performance Computationnelle . . . . . 12
6.5 Discussion et Limites . . . . . 12
6.6 Bilan des performances . . . . . 13

**7 Travaux Futurs** **13**
7.1 Évaluation Quantitative Rigoureuse . . . . . 13
7.2 Détection Améliorée de la Rondelle . . . . . 13
7.3 Stabilisation Temporelle de la Projection 2D . . . . . 13
7.4 Filtrage Géographique pour l'Exclusion des Gradins . . . . . 14
7.5 Export de Données Structurées . . . . . 14
7.6 Support Multi-Caméra et Calibrage Robuste . . . . . 14
7.7 Analyse Temporelle et Modèles Séquentiels . . . . . 15
7.8 Interface Utilisateur Temps Réel . . . . . 15

**Conclusion** **16**

# 1. Objectif de l'Application

## 1.1 Définition du Problème

L'analyse vidéo de matchs sportifs constitue un champ d'application privilégié de la vision par ordinateur, en raison de la densité informationnelle des scènes filmées et des exigences temporelles contraignantes. Dans le contexte du hockey sur glace, la complexité est particulièrement élevée : des athlètes se déplacent à des vitesses pouvant dépasser $40km/h$, la rondelle atteint $170km/h$ en tir, et les occultations mutuelles sont fréquentes dans les zones de forte densité de joueurs.

L'objectif principal de *SideLine AI* est de **automatiser l'extraction d'informations sémantiques** à partir de flux vidéo de matchs de hockey, en opérant en temps quasi-réel. Plus précisément, le système vise à :

— **Détecter et segmenter** l'ensemble des joueurs présents dans chaque image de la séquence vidéo ;
— **Identifier** les joueurs par leur numéro de maillot via une chaîne OCR validée temporellement ;
— **Localiser la rondelle** de manière continue malgré sa petite taille et ses occultations fréquentes ;
— **Projeter** les positions détectées sur un référentiel normalisé de la patinoire (carte 2D à l'échelle) à l'aide d'une transformation homographique calculée en direct ;
— **Produire** une vidéo annotée intégrant des métadonnées visuelles riches (boîtes englobantes, labels d'identité, minimap interactif).

## 1.2 Portée Fonctionnelle

Le système prend en entrée une vidéo MP4 d'un match de hockey et produit en sortie :

1. Une vidéo annotée avec les pistes visuelles de chaque joueur et de la rondelle ;
2. Une représentation 2D dynamique de la patinoire (minimap) indiquant les positions projetées en temps réel ;
3. Les métadonnées positionnelles (coordonnées $(x, y)$ dans le référentiel physique de 200×85 pieds).

# 2. Intention et Motivation

## 2.1 Contexte Industriel et Scientifique

L'analyse automatisée de séquences sportives s'inscrit dans une tendance de fond qui touche l'ensemble des disciplines professionnelles. Les équipes de la *National Hockey League* (NHL) investissent massivement dans des outils d'analytique avancée, tels que le système *SportVU* ou les solutions propriétaires développées par *Sportsradar*. Ces systèmes reposent généralement sur des configurations multicaméras coûteuses et des infrastructures fermées.

*SideLine AI* explore la faisabilité d'une solution alternative, fondée sur des architectures ouvertes et des modèles pré-entraînés accessibles, applicable à une caméra de diffusion standard. Cette approche est motivée par :

1. **L'accessibilité technologique** : les modèles de détection de pointe (YOLO26) sont désormais publiquement disponibles et entraînables sur du matériel grand public, réduisant drastiquement les barrières à l'entrée ;
2. **La richesse sémantique** des vidéos sportives : une seule image contient des informations sur les identités, les positions, les vitesses et les configurations tactiques, que l'œil humain ne peut traiter exhaustivement en temps réel ;
3. **La valeur analytique** : la connaissance précise des positions et des trajectoires des joueurs permet de calculer des statistiques avancées (possession par zone, surfaces couvertes, patterns offensifs) dont l'utilité pour les entraîneurs est documentée dans la littérature [4] ;
4. **La complexité technique** comme vecteur pédagogique : le projet constitue un cas d'étude intégrateur de plusieurs sous-disciplines de la vision par ordinateur (détection, suivi, OCR, géométrie projective), justifiant sa pertinence dans le cadre du cours de Vision Artificielle.

### 2.2 Contribution Pédagogique

Sur le plan académique, ce projet permet de mettre en œuvre et d'intégrer de manière opérationnelle des concepts fondamentaux du cours : la transformation homographique en tant qu'application directe de la géométrie projective, la fusion de plusieurs modalités de perception (détection d'objets, lecture OCR, estimation de points-clés), et la problématique de l'évaluation sans annotation de référence.

## 3. Données Utilisées

### 3.1 Séquence Vidéo Source

Le jeu de données de test principal est une séquence vidéo MP4 de dix secondes extraite d'un match de la NHL opposant les **Montreal Canadiens** aux **Toronto Maple Leafs** (`hockey_Maple_Leafs_vs_Canadiens_10s.mp4`). Ce clip, bien que court, constitue un cas de test suffisamment représentatif pour valider le pipeline dans sa totalité : il contient des joueurs des deux équipes, plusieurs configurations de densité (zones denses et épars), et des instants où la rondelle est partiellement ou totalement occluse.

### 3.2 Absence de Dataset Annoté : Justification

Il convient de souligner que **le projet ne s'appuie pas sur un dataset annoté de type supervisé classique**. Cette décision est motivée par plusieurs considérations :

— **Rareté des annotations publiques en hockey** : contrairement au football/soccer ou au basketball, les datasets de hockey avec annotations de boîtes englobantes, segmentations et keypoints de terrain sont quasi-inexistants dans le domaine public.

— **Stratégie de transfert d'apprentissage** : les modèles YOLO généraux, entraînés sur COCO, généralisent raisonnablement la détection de personnes à la scène de hockey, éliminant le besoin d'un large corpus annoté ;

— **Modèle spécialisé fine-tuné** : le modèle `HockeyAI_model_weight.pt`, un YOLOv8 small disponible en open-source [7], a été fine-tuné sur un corpus

de matchs de hockey pour la détection de keypoints spécifiques (centroïde de patinoire, buts, points de mise au jeu) et de la rondelle, compensant les limitations des modèles généralistes. Il aurait pu être intéressant de procéder à l'entrainement d'un modèle plus récent et performant sur le même dataset, mais nous n'avons pas les capacités de calcul pour faire cela.

### 3.3 Rosters et Métadonnées d'Équipes

En complément de la vidéo, le système intègre les **rosters complets** des deux équipes :

Table 1 – Extrait des rosters intégrés au système

| Équipe | Joueur (exemples) | Numéro | Couleur hex |
|---|---|---|---|
| Canadiens | Nick Suzuki | 14 | `#AF1E2D` |
| | Kirby Dach | 77 | |
| | Sam Montembeault (G) | 35 | |
| | ...(26 joueurs) | – | |
| Maple Leafs | Auston Matthews | 34 | `#9DC1F0` |
| | John Tavares | 91 | |
| | Joseph Woll (G) | 60 | |
| | ...(27 joueurs) | – | |

Ces métadonnées permettent de résoudre les identités au-delà du simple numéro de maillot, en associant chaque identifiant OCR à un nom de joueur répertorié.

## 4. Méthodologie et Pipeline de Traitement

### 4.1 Vue d'Ensemble de l'Architecture Système

Le pipeline de traitement de *SideLine AI* suit une architecture séquentielle modulaire, organisée autour de cinq phases distinctes. La Figure 1 illustre les flux de données entre les composants.

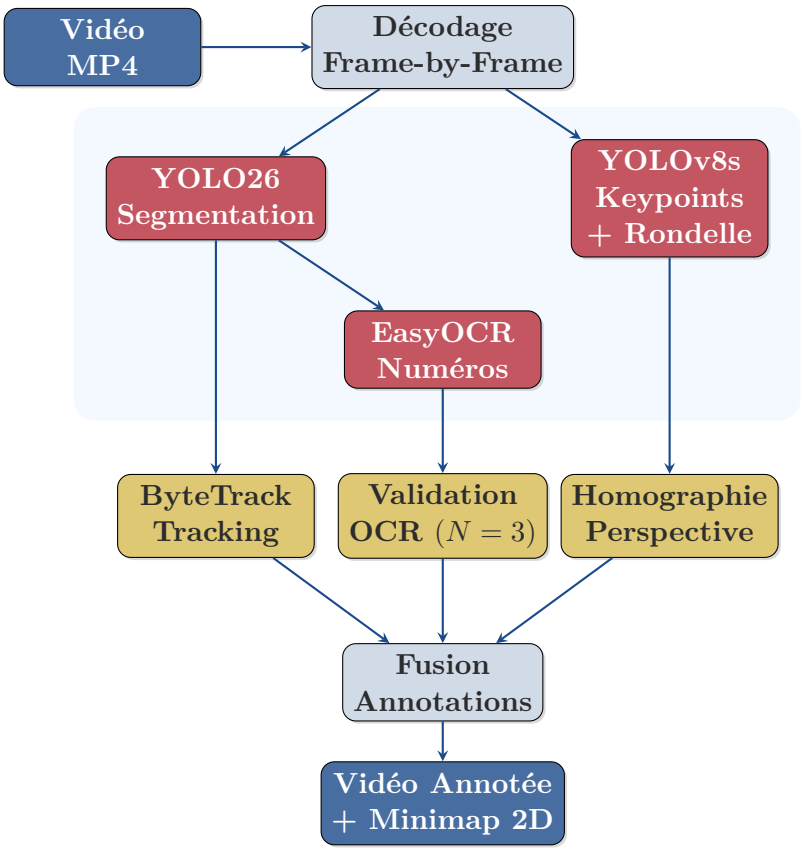


FIGURE 1 – Pipeline de traitement de *SideLine AI*.

## 4.2 Phase 1 : Initialisation du Système

Avant le traitement de la première image, le système procède aux initialisations suivantes :

— Chargement des modèles YOLO depuis le disque, avec détection automatique de la disponibilité des versions OpenVINO [1] optimisées et quantifié (si disponible) ;
— Résolution dynamique des identifiants de classes (*class IDs*) pour les labels `person/player` et `puck` dans les métadonnées du modèle, garantissant la robustesse face aux variations de vocabulaire entre modèles ;
— Instanciation des trackers ByteTrack, un par flux (joueurs, rondelle) ;

## 4.3 Phase 2 : Détection des Joueurs (Branche Segmentation)

### *4.3.1 Expérimentations initiales et sélection du modèle*

Avant de converger vers l'architecture finale, deux approches ont été évaluées en parallèle lors du premier sprint de développement. Une première équipe a identifié et testé un modèle inspiré de l'architecture DETR, pré-entraîné sur des données sportives via le dépôt *Roboflow Sports* [6], couvrant des cas d'usage en basketball et en soccer. Ce modèle permettait de générer rapidement des boîtes englobantes

1. Nous avons utilisé la technologie d'Intel principalement parce qu'elle était la mieux adaptée au matériel disponible sur nos ordinateurs. Le système reste toutefois fonctionnel sur d'autres PC, mais sans bénéficier des mêmes optimisations ni de la quantification.

pour les joueurs et fournissait une base fonctionnelle initiale. Une seconde approche, conduite en parallèle, a orienté le choix vers **YOLO26-L** [8] pour sa capacité de segmentation d'instances et son compromis favorable entre performance et coût de calcul, avec environ 24,8 millions de paramètres. Le modèle DETR a été écarté au profit de YOLO26-L en raison de sa latence d'inférence plus élevée et de l'absence d'une variante de segmentation d'instances native, indispensable à l'extraction précise des crops de maillots pour l'OCR. Cette décision a également facilité l'intégration du second modèle YOLO custom (`HockeyAI_model_weight.pt`) dans un pipeline unifié reposant sur la même bibliothèque Ultralytics.

Chaque frame est soumise au modèle `yolo26l-seg.pt`, un modèle YOLO26-Large de segmentation d'instances, entraîné sur le dataset COCO. La classe cible est `person` (ou `player` selon la nomenclature du modèle). La segmentation, plutôt que la simple détection par boîte englobante, présente deux avantages :

1. Elle fournit un masque précis permettant d'isoler la région du maillot pour l'extraction OCR ;
2. Elle discrimine mieux les joueurs partiellement occultés par la vitre ou par d'autres joueurs.

Les détections sont ensuite transmises à **ByteTrack** pour association inter-frames. ByteTrack [2] maintient un identifiant stable (*tracker_id*) pour chaque joueur tout au long de la séquence, même en cas d'occultation partielle, en exploitant les détections à faible confiance généralement ignorées par les trackers concurrents.

### 4.4 Phase 3 : Classification par K-means (Espace HSV)

L'identification des équipes a été simplifiée par l'application d'un algorithme de clustering non supervisé directement sur les détections :

— **Extraction :** Récupération du masque de segmentation de chaque joueur.
— **Traitement :** Conversion des pixels du masque dans l'espace **HSV** pour isoler la teinte des maillots des variations lumineuses.
— **Clustering :** Application d'un **K-means** ($k = 2$) sur l'ensemble des pixels pour séparer automatiquement les deux couleurs dominantes.

Cette approche permet de distinguer les deux équipes en temps réel, sans connaissance préalable des couleurs ou des compositions (rosters), tout en s'affranchissant des éléments neutres du décor.

### 4.5 Phase 4 : Détection des Keypoints et de la Rondelle (Branche Keypoints)

Exécutée toutes les 3 images, cette branche utilise le modèle custom `HockeyAI_model_weight.pt`, fine-tuné pour détecter :

— **Centroïde** : point central de la patinoire ;
— **Faceoff dots** : points de mise au jeu (zones offensives et neutre) ;
— **Goal frames** : poteaux et ligne de but.

— **Puck** : la rondelle, également suivi par un second ByteTracker.

Un défi spécifique aux diffusions NHL mérite d'être souligné : les angles de caméra changent fréquemment et la vue ne couvre jamais l'intégralité de la patinoire simultanément. En pratique, seuls deux ou trois points fixes sont visibles à un instant donné — typiquement un cercle de mise au jeu et l'un des buts, ou le rond central. Ce faible nombre de correspondances dégrade la précision de l'homographie estimée par RANSAC et provoque des discontinuités dans la minimap. Une solution envisagée consiste à développer un détecteur de points-clés supplémentaire couvrant les lignes bleues et les lignes de but, plus fréquemment visibles, afin d'augmenter la densité de correspondances disponibles pour le calcul de $\mathbf{H}$.

### 4.6 Phase 5 : Calcul de l'Homographie

La transformation homographique est au cœur de la projection 2D. Elle est calculée via la fonction `cv2.findHomography()` d'OpenCV, qui résout le système $\mathbf{H}\mathbf{p}_i \sim \mathbf{p}'_i$ pour au minimum 4 correspondances de points, en utilisant l'estimateur RANSAC pour la robustesse aux outliers :

$$\begin{pmatrix} x' \\ y' \\ 1 \end{pmatrix} \sim \mathbf{H} \begin{pmatrix} x \\ y \\ 1 \end{pmatrix}, \quad \mathbf{H} \in \mathbb{R}^{3\times 3} \tag{1}$$

où $(x, y)$ sont les coordonnées pixel dans l'image de diffusion, et $(x', y')$ les coordonnées physiques dans le référentiel de la patinoire (en pieds).

On résout l'ambiguïté de correspondance par une heuristique spatiale : la position relative (gauche/droite, haut/bas) des keypoints détectés est comparée à la configuration connue des repères de la patinoire officielle (200×85 ft, NHL). Cette correspondance est validée avant chaque mise à jour de $\mathbf{H}$.

### 4.7 Phase 6 : Identification OCR des Numéros de Maillots

Cette branche extrait la région centrale de la boîte englobante de chaque joueur (crop du maillot) et la soumet à EasyOCR avec une *allowlist* restreinte aux chiffres (`0-9`). Le résultat brut est filtré par le composant `OCRHistoryTracker` :

$$\text{ID_confirmé}(t) = \begin{cases} n & \text{si count}(n, t-N:t) \geq N \\ \text{None} & \text{sinon} \end{cases} \quad \text{avec } N = 3 \tag{2}$$

Ce filtre de consensus temporel élimine les fausses lectures (artefacts visuels, reflets sur la glace, numéros partiellement visibles) en exigeant une confirmation sur $N$ lectures consécutives.

### 4.8 Phase 7 : Rendu et Composition Finale

La dernière phase assemble les sorties de toutes les branches :

— Les boîtes englobantes et labels (numéro ou tracker_id) sont dessinés via `supervision.BoxAnnotat` et `supervision.LabelAnnotator` ;

— La minimap 2D est générée par `draw_hockey_rink_2d()`, qui dessine la patinoire normalisée avec ses repères réglementaires (lignes rouges, bleues, cercles de mise au jeu) ;
— Les positions projetées des joueurs et de la rondelle sont superposées sur la minimap via `draw_points_on_rink()`.

# 5. Architecture des Réseaux de Neurones

## 5.1 YOLO26 — Détection et Segmentation

### *5.1.1 Justification du Choix*

L'architecture YOLO26 (You Only Look Once, version 2026) [8] a été retenue pour trois raisons principales :

1. **Performance temps réel** : YOLO26 opère en un seul passage (*single-stage*), contrairement aux architectures à deux étapes (Faster R-CNN), ce qui garantit une latence adaptée au traitement vidéo ;
2. **Variante segmentation** : la tâche `-seg` produit des masques d'instance, supérieurs aux boîtes englobantes pour l'extraction de crops de maillots ;
3. **Variante "keypoints"** : Même si le modèle custom est entrainé pour la détection, on utilise les résultats comme des keypoints et permet la détection structurée de points caractéristiques du terrain.

### *5.1.2 Deux Modèles, Deux Fonctions*

Table 2 – Comparaison des deux modèles YOLO utilisés

| Modèle | Tâche | Classes cibles | Taille |
|---|---|---|---|
| `yolo26l-seg.pt` | Segmentation | person/player | Large |
| `HockeyAI_model_weight.pt` | Detect | keypoints, puck | custom |

## 5.2 ByteTrack — Suivi Multi-Objets

ByteTrack [2] adopte une stratégie d'association à deux niveaux : les détections à haute confiance sont associées en priorité aux pistes existantes via la distance IoU (*Intersection over Union*), puis les détections à faible confiance — normalement ignorées — sont utilisées dans un second passage pour récupérer des pistes perdues. Cette stratégie est particulièrement adaptée au hockey où les joueurs peuvent être partiellement occultés par la vitre ou d'autres joueurs.

## 5.3 EasyOCR — Reconnaissance de Caractères

EasyOCR [3] repose sur une architecture combinant un backbone CNN (ResNet) pour l'extraction de features visuelles et un module LSTM bidirectionnel suivi d'un décodeur CTC (*Connectionist Temporal Classification*) pour la transcription séquentielle. La restriction de l'*allowlist* aux caractères numériques réduit considérablement l'espace de recherche et améliore la précision sur les numéros de maillots.

### 5.4 ViTPose — Estimation de Pose (Phase Exploratoire)

Au cours du premier sprint de développement, le modèle **ViTPose** [9] a été intégré au pipeline à titre exploratoire pour l'estimation de pose des joueurs. Cette architecture, fondée sur des *Vision Transformers*, prédit les points-clés anatomiques du corps humain (épaules, coudes, poignets, hanches, genoux, chevilles) à partir des crops issus des boîtes englobantes YOLO.

Cette composante a servi à la **validation qualitative** du système : les squelettes générés ont permis de confirmer visuellement la cohérence des détections sur des séquences test issues de matchs NBA et NHL. L'objectif à terme était d'exploiter ces poses comme variables d'entrée pour une **classification d'actions** (tir, passe, mise en échec), en s'appuyant sur un classificateur entraîné à partir des vecteurs de keypoints.

Cependant, ViTPose n'a pas été retenu dans le pipeline final pour plusieurs raisons pratiques : le surcoût de calcul qu'il implique en mode séquentiel est incompatible avec les contraintes de quasi-temps réel, et l'absence de données d'entraînement étiquetées pour les actions hockey rendait impossible l'entraînement d'un classificateur aval. Ce composant reste documenté ici comme piste d'extension future, dans le cadre du volet analyse temporelle et modèles séquentiels décrit à la section Travaux Futurs.

### 5.5 Optimisation par OpenVINO

Les versions *int8* compressées via OpenVINO permettent une réduction de la mémoire nécessaire d'un facteur 4× par rapport au format float32, et une accélération de l'inférence CPU/GPU de l'ordre de 2× à 3× selon le matériel. Le système adopte un mécanisme de *fallback* : si les modèles OpenVINO sont présents, ils sont chargés préférentiellement ; sinon, les modèles PyTorch standards sont utilisés.

## 6. Analyse des Résultats

### 6.1 Contexte Évaluatif et Limitations Méthodologiques

La question de l'évaluation rigoureuse de *SideLine AI* soulève une problématique fondamentale : **l'absence de *ground truth* annoté** pour les données vidéo traitées. En effet, l'évaluation supervisée classique requiert, pour chaque image, la connaissance exhaustive des boîtes englobantes de référence, des identités de joueurs, des positions réelles sur la glace, et de la position exacte de la rondelle. Or, la constitution de telles annotations est extrêmement coûteuse en temps et en expertise humaine, et aucun corpus public de ce type n'existe pour le hockey sur glace.

Par conséquent, les métriques supervisées standards — telles que le **mAP** (*mean Average Precision*), l'**IoU** (*Intersection over Union*), le **MOTA** (*Multiple Object Tracking Accuracy*) ou le **F1-score** OCR — ne peuvent pas être calculées dans leur sens strict. Cette situation est néanmoins documentée dans la littérature de vision par ordinateur appliquée au sport comme une contrainte récurrente [4], et plusieurs stratégies d'évaluation alternatives sont proposées.

### 6.2 Évaluation Qualitative par Inspection Visuelle

La première approche d'évaluation consiste en l'**inspection visuelle systématique** des prédictions produites sur la séquence de test. Cette méthode, bien que non formalisable statistiquement, permet d'identifier les catégories de succès et d'échec :

— **Détection des joueurs** : le modèle segmente correctement l'ensemble des joueurs visibles dans les plans larges. Les faux négatifs sont observés principalement dans les zones de forte occultation (mêlées devant le filet) et lorsqu'un joueur est partiellement sorti du cadre. Les faux positifs concernent principalement les arbitres et, à l'occasion, des spectateurs proches de la vitre ;
— **Stabilité du suivi** : ByteTrack maintient des identifiants stables sur l'ensemble du clip de 10 secondes, avec de rares *identity switches* lors de croisements de joueurs ;
— **Projection homographique** : la minimap 2D reflète fidèlement les configurations spatiales observées à l'écran, validant qualitativement la cohérence géométrique de la transformation.

### 6.3 Robustesse aux Conditions Dégradées

Le clip de test présente plusieurs conditions dégradées qui permettent d'évaluer qualitativement la robustesse du système :

1. **Flou de mouvement** : lors des phases de jeu rapide, les joueurs présentent un flou cinétique. Le modèle maintient des détections valides avec une légère diminution des scores de confiance ;
2. **Occultations par la vitre** : les reflets sur la vitre de protection génèrent des artefacts visuels. Le filtre de consensus OCR ($N = 3$) absorbe efficacement ces bruits ponctuels ;

### 6.4 Performance Computationnelle

La performance en termes de débit de traitement (*throughput*) est une métrique objective mesurable indépendamment de l'annotation. Les optimisations implémentées (traitement périodique, OpenVINO int8) visent à maintenir un rapport frames traitées / temps écoulé acceptable pour un usage quasi-temps réel. Le temp d'inférence sur iGPU est d'environ 2 FPS. Cela ne permet pas un usage en temps réel cependant des pistes d'améliorations sont possibles : usage de véritables GPUs puissants, distribution des tâches, optimisation d'easyOCR qui est le principal bottleneck.

### 6.5 Discussion et Limites

L'évaluation reste intrinsèquement limitée par l'absence d'annotations de référence. Les résultats présentés ci-dessus doivent être interprétés avec la prudence requise : les scores de confiance sont des indicateurs internes au modèle et ne reflètent pas nécessairement la précision réelle des prédictions. Une validation quantitative rigoureuse nécessiterait au minimum 200 à 500 frames annotées manuellement, constituant un axe de travail futur prioritaire.

### 6.6 Bilan des performances

— **Fausses détections dans les gradins** : le modèle, entraîné sur COCO, détecte systématiquement des spectateurs proches de la vitre. Un filtrage géographique par masque de la surface de glace permettrait de réduire ce bruit sans retraining ;
— **Instabilité du clustering d'équipes** : le regroupement des joueurs par couleur de maillot est perturbé par les casques sombres, les protège-tibias noirs et les reflets de la glace. Restreindre l'analyse chromatique à la seule zone du torse améliorerait la stabilité du clustering ;
— **Fiabilité de l'OCR** : les mouvements rapides et les plis des maillots génèrent des lectures erronées malgré le filtre de consensus ($N = 3$). Un prétraitement par augmentation de contraste localisée sur le crop du maillot constitue une amélioration à fort rapport coût/bénéfice ;
— **Discontinuités de la minimap** : des erreurs d'estimation temporaires des keypoints provoquent des « téléportations » des joueurs sur la projection 2D. Un lissage temporel par moyennage glissant des positions, ou par filtre de Kalman, stabiliserait ces trajectoires.

## 7. Travaux Futurs

### 7.1 Évaluation Quantitative Rigoureuse

La priorité est la constitution d'un **petit corpus annoté de référence**. L'annotation d'une centaine de frames avec des boîtes englobantes, les identités des joueurs, et la position de la rondelle permettrait de calculer les métriques standards (mAP, MOTA, MOTP) et de situer objetivement les performances du système par rapport à l'état de l'art.

### 7.2 Détection Améliorée de la Rondelle

La détection de la rondelle reste le composant le plus fragile. Plusieurs pistes sont envisageables :

— **Soustraction de fond temporel** : exploiter la différence inter-frames pour détecter les objets en mouvement rapide ;
— **Modèle dédié haute résolution** : entraîner un détecteur sur des crops à haute résolution de la zone de jeu ;
— **Prédiction de trajectoire** : utiliser un filtre de Kalman pour prédire la position probable de la rondelle entre les détections.

### 7.3 Stabilisation Temporelle de la Projection 2D

Les discontinuités observées dans la minimap — joueurs se « téléportant » d'un point à un autre suite à des erreurs ponctuelles dans l'estimation des keypoints de la patinoire — constituent une limite fonctionnelle notable. Deux approches complémentaires sont envisagées :

1. **Lissage par moyennage glissant** : les coordonnées projetées de chaque joueur sont moyennées sur une fenêtre temporelle de $k$ images consécutives, écrêtant les sauts aberrants sans introduire de délai perceptible ;

2. **Filtre de Kalman par piste** : un filtre de Kalman linéaire maintenu par joueur permet de prédire la position attendue entre deux estimations valides, assurant une trajectoire physiquement cohérente même lors des occultations ou des changements de vue.

### 7.4 Filtrage Géographique pour l'Exclusion des Gradins

Le modèle de détection YOLO26, entraîné sur COCO, identifie les spectateurs proches de la vitre comme des personnes valides, polluant le tracking et la minimap. Un **masque géographique de la surface de glace**, calculé une fois par séquence à partir des keypoints de la patinoire détectés, permettrait de restreindre la zone de détection active à la surface de jeu. Ce filtre réduirait les fausses détections, allégerait la charge de calcul du tracker et améliorerait la lisibilité de la projection 2D, sans nécessiter de réentraînement du modèle de détection.

### 7.5 Export de Données Structurées

La projection homographique génère des coordonnées physiques $(x, y)$ en pieds pour chaque joueur et pour la rondelle. L'export de ces données vers des formats structurés (JSON, CSV) ouvrirait la voie à des analyses statistiques avancées : calcul de la surface couverte par chaque joueur, temps de possession par zone, identification de patterns tactiques récurrents.

### 7.6 Support Multi-Caméra et Calibrage Robuste

L'extension à un système multi-caméra (plusieurs angles de vue) nécessiterait un calibrage extrinsèque cross-caméra. Ce calibrage permettrait d'obtenir une couverture spatiale complète de la patinoire et d'éliminer les zones d'ombre liées aux angles morts d'une caméra unique.

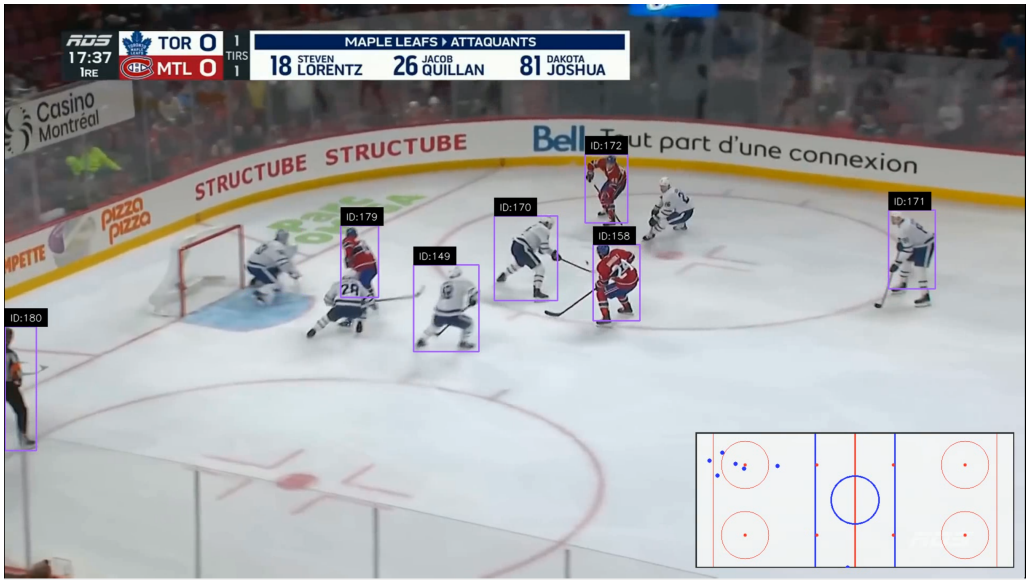


FIGURE 2 – Analyse visuelle complémentaire du système.

### 7.7 Analyse Temporelle et Modèles Séquentiels

L'intégration de modèles séquentiels (LSTM, Transformer temporel) permettrait de modéliser les **trajectoires futures** des joueurs et de la rondelle, ouvrant la possibilité de systèmes prédictifs pour l'anticipation tactique en temps réel.

### 7.8 Interface Utilisateur Temps Réel

Le développement d'une interface web (basée sur WebRTC ou HLS) permettrait la diffusion en streaming des sorties annotées, rendant le système accessible aux entraîneurs sans installation locale. La minimap pourrait être rendue interactive, permettant le clic sur un joueur pour accéder à ses statistiques de match.

## Conclusion

En conclusion, *SideLine AI* démontre qu'il est possible de construire un système d'analyse vidéo de hockey pertinent à partir de briques modernes de vision par ordinateur intégrées dans un pipeline unique. La combinaison de la détection, du suivi multi-objets, de l'OCR et de la projection homographique permet d'extraire automatiquement des informations utiles à partir d'un simple flux vidéo de diffusion.

Le projet met également en évidence l'intérêt d'une architecture modulaire : chaque composant peut être amélioré indépendamment, tandis que les optimisations mises en place, notamment le traitement périodique et l'utilisation d'OpenVINO lorsque disponible, permettent d'obtenir un niveau de performance compatible avec un usage quasi temps réel sur du matériel accessible.

Certaines limites demeurent cependant, en particulier l'absence d'un jeu de données annoté permettant une évaluation quantitative rigoureuse. Malgré cela, les résultats qualitatifs obtenus montrent que l'approche est crédible, fonctionnelle et suffisamment robuste pour servir de base à des développements futurs.

Au-delà des résultats techniques, ce projet a également constitué une expérience particulièrement enrichissante sur le plan pédagogique. Il nous a permis de mobiliser de manière concrète plusieurs notions du cours — détection, suivi, OCR, homographie, optimisation d'inférence et intégration de pipeline — dans un cadre applicatif réaliste, avec les compromis méthodologiques et techniques que cela implique.

Ainsi, ce travail constitue à la fois une démonstration technique, une fondation concrète pour des extensions ultérieures, et un cas d'étude formateur, qu'il s'agisse d'améliorer la détection de la rondelle, d'enrichir l'analyse tactique ou de déployer le système dans un contexte d'utilisation réel.

## Références

[1] Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLO* (Version 8.0.0) [Computer software]. https://github.com/ultralytics/ultralytics

[2] Zhang, Y., Sun, P., Jiang, Y., Yu, D., Weng, F., Yuan, Z., ... & Wang, X. (2022). ByteTrack : Multi-Object Tracking by Associating Every Detection Box. *European Conference on Computer Vision (ECCV)*. https://arxiv.org/abs/2110.06864

[3] JaidedAI. (2020). *EasyOCR : Ready-to-use OCR with 80+ supported languages*. https://github.com/JaidedAI/EasyOCR

[4] Giancola, S., Amine, M., Dghily, T., & Ghanem, B. (2018). SoccerNet : A Scalable Dataset for Action Spotting in Soccer Videos. *CVPR Workshop on Computer Vision in Sports*.

[5] Bradski, G. (2000). The OpenCV Library. *Dr. Dobb's Journal of Software Tools*, 120, 122–125.

[6] Skalski, P. (2023). *Supervision : Computer Vision Utilities and Tools*. Roboflow. https://github.com/roboflow/supervision

[7] SimulaMet-HOST. (s.d.). *HockeyAI*. Hugging Face. https://huggingface.co/SimulaMet-HOST/HockeyAI

[8] Sapkota, R., Cheppally, R. H., Sharda, A., & Karkee, M. (2026). YOLO26 : Key Architectural Enhancements and Performance Benchmarking for Real-Time Object Detection. *arXiv preprint*.

[9] Xu, Y., Zhang, J., Zhang, Q., & Tao, D. (2022). ViTPose : Simple Vision Transformer Baselines for Human Pose Estimation. *Advances in Neural Information Processing Systems (NeurIPS)*. https://arxiv.org/abs/2204.12484